2021 年 8 月 计 算 数 学 第 43 卷第 3 期
Aug., 2021 MATHEMATICA NUMERICA SINICA Vol.43, No.3

doi: 10.12286/jssx.j2021-0833

青年评述

机器学习原子间相互作用建模*1)

王 涵2)

(北京应用物理与计算数学研究所计算物理实验室, 北京 100094;
北京大学工学院应用物理与技术中心, 北京 100871)

摘 要

原子间相互作用建模是分子动力学模拟的核心问题之一. 基于第一性原理的建模准而不快, 经验势模型快而不准, 因此人们长期面临精度和效率只得其一的两难困境. 基于机器学习的原子间相互作用建模在达到第一性原理精度的同时, 计算开销大大降低, 因而有希望解决这一两难困境. 本文将介绍构造基于机器学习的原子间相互作用模型的一般框架, 归纳近年来的主要建模工作, 并探讨这些工作的优势和劣势.

关键词: 机器学习; 原子间作用势; 分子动力学模拟.

MR (2010) 主题分类: 68T99, 74A25, 81V55.

1. 引 言

分子动力学模拟是一种在计算机上进行的虚拟实验. 在分子动力学模拟中, 原子被视为质点, 质点的位置和速度是分子动力学处理的变量. 在给定原子初始坐标和初始速度的前提下, 通过求解运动方程得到原子随时间的运动轨迹. 在不同的宏观热力学控制条件下, 分子动力学求解不同的运动方程获得对相应的系综的采样. 例如微正则系综需要求解 Hamilton 系统, 正则系综需要求解 Nose-Hoover 动力学或 Langevin 动力学. 假设我们可以求解无穷长的原子运动轨道, 且在遍历性假设成立的条件下, 这些轨道经历的体系状态对应相应系综分布的一个采样. 体系的大量可观测性质可以写为相应系综下的期望或时间关联函数, 因此可以通过分子动力学模拟进行计算.

分子动力学模拟的精度的衡量标准并非求解的运动方程的精度, 而是采样目标系综的精度. 这个精度涉及两个问题: (1) 有限长时间中解出的分子动力学轨道是否可以认为是目标系综的一个充分的采样. 这往往涉及到体系中是否存在 “稀有事件” , 以及如何加速分子动力学的采样过程, 使得实际采样尽快收敛到目标系综分布. 这方面的工作是分子动力学模拟方法的一个重要的发展方向, 相关的进展可以参考综述文章如文献 [1–3]. (2) 假设分子动力学模拟时间足够长, 轨道是目标系综的一个充分采样, 下面的问题是目标系综和客观世界中体系状态的分布是否一致. 由于系综分布由体系的 Hamiltonian 定义, 这个问题等价于分子动力学模拟

* 2021 年 7 月 4 日收到.

1) 基金项目: 国家自然科学基金 (11871110) 资助.

2) 作者简介: 王涵, 北京应用物理与计算数学研究所特聘研究员, 博士生导师. 主要研究兴趣为分子动力学模拟中的多尺度建模与计算方法. 与合作者发展了基于深度学习的原子间相互作用建模与计算方法, 将第一原理精度分子动力学模拟规模推进至亿原子量级. 2019 年受北京市科学技术协会青年人才托举工程资助, 并获得中国数学会计算数学分会青年创新奖. 2020 年获得 ACM 戈登贝尔奖, 并入选当年两院院士评选的中国十大科技进展.

使用的体系 Hamiltonian 是否和客观世界一致. Hamiltonian 由动能项和势能项组成, 动能项是平凡的, 势能项的精度起了决定作用. 因此, 分子动力学模拟中使用的原子相互作用势的建模 (势能项建模) 能否正确反应客观世界, 决定了分子动力学模拟的精度. 在本文中, 我们暂时不讨论问题 (1) , 而集中讨论问题 (2), 以及机器学习方法是如何在问题 (2) 的处理中发挥作用的.

精确的原子相互作用由量子力学的基本原理给出. 在 Born-Oppenheimer 近似 [4] 下, 一个原子体系的基态能量可以通过求解电子的非含时薛定谔方程 [5] 获得. 这一般而言意味着求解一个高维线性特征值问题, 这在数值上是非常困难的. 因此, 一般而言人们会退而求其次, 求解薛定谔方程的某个近似问题来获得体系的基态能量. 这里的近似问题可以是密度泛函理论 [6,7], 或者量子化学方法如 Møller-Plesset 扰动理论 [8]、耦合簇方法 [9] 等. 目前基于求解量子力学原理的分子动力学模拟, 即第一性原理分子动力学模拟 (*ab initio* molecular dyanmics, AIMD), 一般使用密度泛函理论求解体系的基态电子结构 [10], 从而获得体系基态能量. 虽然密度泛函理论求解一个三维空间中的非线性特征值问题, 相比求解非含时薛定谔方程已经相对快速, 但是其计算开销随体系中电子数的增长速度为三次方, 一般而言无法对大体系进行计算. 对薛定谔方程更精确的近似方法一般计算开销也更大.

给出原子相互作用势的另一种方式是经验力场, 即通过物理/化学知识猜测体系能量具有某种表达形式, 再以实验或第一性原理计算结果拟合表达式中的参数. 经验力场经过四十余年的高速发展, 形成了若干比较成熟的工作, 包括 Gromos [11,12], CHARMM [13–16], Amber [17–19], OPLS-AA [20], 反应力场 [21–23], 材料力场建模方法——嵌入原子方法 (Embedded atom method) 和修正嵌入原子方法 (Modified embedded atom method) [24–26]. 经验力场模拟效率非常高, 最大体系规模甚至达到 20×10^{12} 原子 [27]. 然而, 经验力场具有两个值得考虑的问题：可表示性问题和可移植性问题. 可表示性问题指凭经验猜测的函数形式是否能表示第一性原理的能量, 或者假设的函数形式是否能正确重现体系的宏观性质. 可移植性问题指在经验力场被参数化的状态之外, 力场是否还具有高精度. 一般而言, 力场假设的函数形式比较简单, 例如两体或三体截断施加, 而第一性原理能量是一个未知的非线性多体能量, 因此力场无法避免一定程度上的可表示性问题. 同时, 由于在函数形式中考虑了物理/化学基本原理, 经验力场一般被认为具有一定的可移植性, 但是这是没有理论保证的. 因此, 在做分子动力学模拟时, 研究者面临着这样的两难困境——在精度和效率中抉择：要么选择第一性原理计算, 非常昂贵, 但是精度有保证; 要么选择经验力场, 效率高但是精度没有保证.

近年来, 基于机器学习的原子间相互作用建模 (简称为机器学习力场) 得到了快速发展 [28–41]. 机器学习力场是一种从数据出发的近似第一性原理原子相互作用的方法, 由于机器学习对高维函数的强大表示能力, 机器学习力场一般被认为解决了可表示性问题. 在可移植性方面, 虽然一般机器学习力场都在构造中加入了对基本物理规律 (广延性、对称不变性等) 的保证, 但是一般而言机器学习力场的可移植性不佳. 有作者指出在机器学习力场构造中应放弃对可移植性的追求, 而在数据中做到尽可能多样, 覆盖所有可能在应用中出现的情况 [42]. 目前, 很多机器学习力场使用主动学习/同步学习算法生成数据 [43–52], 做到数据尽可能覆盖所有可能的应用场景. 主动学习/同步学习的想法都是类似的, 首先提供机器学习模型的误差估计, 之后在给定数据集 (主动学习) 或由机器学习模型生成的数据集 (同步学习) 中, 根据估计选出误差较大的构型打标签, 最后将标签数据加入训练集更新模型. 主动学习/同步学习一般能产生一定范围内具有一致精度的的模型, 能够在一定应用场景下对物质进行准确模拟 [53,54].

机器学习力场是一个飞速发展的领域, 每年均有大量新工作发表. 本文首先介绍设计机器学习力场的一些基本要求, 再对目前文献中的机器学习力场的设计进行一个不完全的归纳总结, 其中包括拟合方法和描述子构造两部分, 最后讨论目前机器学习力场设计中的一些开放问题.

2. 机器学习力场构造

在本文中, 我们记体系能量为 E, 体系中原子数为 N, 原子坐标为 $\mathcal{R}=\{\boldsymbol{r}_1,\boldsymbol{r}_2,\ldots,\boldsymbol{r}_N\}$. 一般地我们可以通过第一性原理计算得到体系的能量 $E=E(\mathcal{R})$, 并且这些能量一般被认为是非常精确的. 体系的受力被定义为体系能量对原子坐标的负梯度, 第 i 个原子上的受力 $\boldsymbol{F}_i$ 可定义为

$$\boldsymbol{F}_i=-\nabla_{\boldsymbol{r}_i}E, \tag{2.1}$$

分子动力学中一般使用周期性边界条件, 我们记周期性模拟区域的三个基矢量为 $\{\boldsymbol{h}_1,\boldsymbol{h}_2,\boldsymbol{h}_3\}$, 记 $h_{\alpha\beta}$ 为第 α 个基矢量的第 β 个分量. 体系的维里 (virial) 张量的 $\alpha\beta$ 分量被定义为

$$\Xi_{\alpha\beta}=-\frac{\partial E}{\partial h_{\gamma\alpha}}h_{\gamma\beta}, \tag{2.2}$$

机器学习力场的训练是一个典型的监督学习过程. 给定若干组体系原子坐标, 使用第一性原理计算其体系能量、原子受力以及维里, 这些信息可以作为机器学习力场的训练标签. 我们记一个机器学习力场为 $E^w(\mathcal{R})$ 其中 w 是模型参数, 则使用上述标签对机器学习力场的训练可以表示为对如下损失函数的极小化:

$$\begin{aligned}\mathcal{L}=\frac{1}{|\mathcal{B}|N^2}\Big\{\sum_{k\in\mathcal{B}}\Big(&p_e\|E(\mathcal{R}^{(k)})-E^w(\mathcal{R}^{(k)})\|^2+p_f\|\boldsymbol{F}(\mathcal{R}^{(k)})-\boldsymbol{F}^w(\mathcal{R}^{(k)})\|^2\\&+p_v\|\boldsymbol{\Xi}(\mathcal{R}^{(k)})-\boldsymbol{\Xi}^w(\mathcal{R}^{(k)})\|^2\Big)\Big\},\end{aligned} \tag{2.3}$$

其中 $\mathcal{B}$ 是训练所用的数据批次 (batch), $|\mathcal{B}|$ 是该批次中数据个数. p_e, p_f 和 p_v 分别是能量、受力和维里损失的组合系数, 由用户给定或者根据学习率调整 [38].

在物理上体系的能量是广延的, 即宏观上观察到的能量和体系中原子的个数成正比. 因此机器学习力场一般具有如下的能量分解形式:

$$E^w=\sum_{i=1}^N E_i^w=\sum_{i=1}^N E_i^w(\mathcal{R}_i), \tag{2.4}$$

其中 E_i^w 为第 i 个原子的能量贡献. 显然, 只要我们分别对每个 E_i^w 进行建模, 就可以得到一个具有广延性的能量形式. 在机器学习力场建模中, 一般会假设原子能量贡献的局域依赖性, 即 E_i^w 只依赖于原子 i 的坐标及其近邻原子坐标. 其中近邻一般指以 i 为中心, 以截断半径 r_c 为半径的球内所有的原子. 我们记 E_i^w 依赖的原子的集合为 $\{i\}\bigcup\mathcal{N}_i$, 其中近邻集合 $\mathcal{N}_i=\{j:r_{ij}\le r_c\}$, 其中 $r_{ij}=|\boldsymbol{r}_{ij}|=|\boldsymbol{r}_i-\boldsymbol{r}_j|$. 记所有近邻的相对坐标形成的矩阵为环境矩阵 $\mathcal{R}_i$, 环境矩阵有 $N_i=|\mathcal{N}_i|$ 行, 其中第 j 行为第 j 个邻居的相对坐标

$$(\mathcal{R}_i)_{j,\cdot}=(\boldsymbol{r}_{ij}). \tag{2.5}$$

注意局域依赖性是一个假设. 体系中的非局域相互作用, 一般也被称为长程相互作用的主要来源是电子密度的长程库伦相互作用. 对于金属体系, 由于屏蔽效应, 局域依赖一般是一

个合理的假设. 对于均匀的, 且局域电中性、局域无极化的体系, 长程相互作用为四极子间的相互作用, 随原子距离增加以 r^{-5} 的速度衰减, 截断半径外的贡献随 r_c 增大迅速减弱为 0, 这时局域依赖是一个很好的假设, 即取足够大的 r_c 局域依赖假设总能得到满足. 对于一些长程相互作用具有本质性贡献的体系, 需要在模型构造中显式地考虑长程相互作用. 比如一些工作中为每个原子训练一个部分电荷 (partial charge), 以部分电荷间的静电相互作用建模体系的长程相互作用 [41,55–57]. 这类方法的问题是部分电荷依赖于对第一性原理电子密度的某种分解, 而这类分解在物理上并没有明确的定义, 而且部分电荷按照不同分解方法的计算结果在一些情况下甚至有定性的差别 [58,59]. 在部分电荷基础上, 原子的极化效应可以自洽地被引入, 表现为部分电荷的电量转移 [60–62]. 然而这些模型依赖一个没有物理意义的经验参数——原子硬度, 一个原子电负性对原子极化的依赖参数, 这个参数一般是通过数据训练的, 而不是从物理原理中获得. 最后, Grisafi 等人将长程电荷密度的特征引入原子能量贡献的构造, 能够突破局域性依赖假设 [63,64], 但是这种长程依赖的引入方式缺乏物理意义, 是一种依赖数据的建模方法. 由于目前对长程相互作用并没有公认的良好的处理方式, 本文中我们总是假设 E_i^w 的局域依赖性.

一个体系的能量满足一系列对称性要求, 这包括平移、旋转、交换对称性, 即体系的能量在原子坐标的平移、旋转、交换操作下是不变的. 一般地, 我们有约束

$$E(\mathcal{R}) = E(U\mathcal{R}), \tag{2.6}$$

其中 U 是对体系坐标的对称操作. 对于一个机器学习模型, 比如全连接神经网络, 一般是不满足对称性的. 为了使模型保持基本物理规律的正确性, 一个常见的做法是对数据做增广. 假设 $(\mathcal{R}^{(k)}, E^{(k)})$ 是数据集中的一点, $E^{(k)}$ 是标签, 增广后的数据点为 $\{(U\mathcal{R}^{(k)}, E^{(k)})\}_{U\in\mathcal{U}}$, 其中 $\mathcal{U}$ 为所有对称操作组成的集合. 这种做法的缺点是：首先对称性 (2.6) 不能严格保证; 其次 $\mathcal{U}$ 一般是一个很大的集合, 对其中元素做充分采样意味着海量数据. 因此目前最常见的做法是在模型构造层面满足对称性要求, 即

$$E_i^w(\mathcal{R}_i) = E_i^w(U\mathcal{R}_i), \tag{2.7}$$

为了达到这样的设计, 人们一般引入描述子的概念,

$$\mathcal{D}(\mathcal{R}_i) = \mathcal{D}(U\mathcal{R}_i), \quad \forall U \in \mathcal{U} \tag{2.8}$$

并将原子能量贡献写成如下形式

$$E_i^w(\mathcal{R}_i) = \mathcal{F}(\mathcal{D}(\mathcal{R}_i)), \tag{2.9}$$

描述子 (2.8) 是一个对原子坐标的映射, 满足所有对称性要求, 且具有足够的分辨能力. 足够分辨能力是指, 对于在对称操作意义下不等价的坐标, 描述子也要不同. 这个要求能够排除一些平凡的描述子构造, 比如坐标的常值映射. 公式 (2.9) 中的 $\mathcal{F}$ 为拟合方法, 一般选为线性函数, 核函数, 或者深度神经网络. 一般要求拟合方法有足够的能力表示高维非线性函数. 为了能解析地计算原子受力和维里, 我们还要求原子能量贡献对坐标尽可能光滑.

综上所述, 我们要求势函数模型具有如下性质: (1) 广延性; (2) 对称操作下的不变性; (3) 光滑性. 广延性有求和构造 (2.4) 保证. 对称操作不变性由描述子保证. 光滑性则由描述子和拟合方法的光滑性共同保证. 下面, 我们将在 2.1 中介绍核函数和深度神经网络两种拟合方法, 在 2.2 中介绍目前一些主要的描述子构造.

2.1. 拟合构造

2.1.1. 核方法

我们在稍微一般的设置下引入核方法的概念. 首先假设 $\{x_1,\ldots,x_M\}$ 是我们的训练数据集, $\{y_1,\ldots,y_M\}$ 是其对应的标签, 我们希望构造拟合 $\mathcal{F}(x)$ 使得其在数据上的值尽可能和标签接近. 核方法做法如下, 首先假设

$$\mathcal{F}(x)=\sum_{i=1}^{M}\alpha_i K(x,x_i), \tag{2.10}$$

其中 α_i 是待定系数. K 是核函数, 一般要求核函数平方可积, 且是半正定的, 即

$$\int dxdy f(x)f(y)K(x,y)\geq 0,\ \forall f\in L^2,$$

核方法的光滑性由核函数的光滑性保证. 高斯函数是一种常用的核函数 [30]. 这里我们记核矩阵 $K_{ij}=K(x_i,x_j)$, 则可以证明如下方程

$$(K+\theta I)\alpha=y \tag{2.11}$$

的解是如下损失函数极小化问题的解

$$\min_{\alpha}\frac{1}{2}\|y-K\alpha\|^2+\frac{\theta}{2}\alpha^T K\alpha, \tag{2.12}$$

其中 $\alpha=(\alpha_1,\ldots,\alpha_M)^T$, $y=(y_1,\ldots,y_M)^T$. (2.12) 中的第一项衡量在配置点 x_i 上核函数 (2.10) 与标签的差. 第二项为正则化项. 值得注意的是核函数求值计算的开销与数据量 M 成正比. 但是由于核函数平方可积, 一般可以对核 K 做截断, 使得实际 (2.10) 中求和项数远小于 M, 或者使用如 CUR 分解 [65] 等技术约化数据集 [66].

2.1.2. 深度神经网络

近年来, 深度学习在计算机视觉 [67], 自然语言处理 [68], 蛋白质折叠 [69] 等领域取得了相比传统方法压倒性的成功. 深度学习的基础是深度神经网络对高维非线性函数的强大拟合能力 [70]. 前馈深度神经网络是一个多层复合函数, 对于任意输入 $x\in\mathbb{R}^{n_1}$

$$\mathcal{F}(x)=\mathcal{L}_O\circ\mathcal{L}_P\circ\cdots\circ\mathcal{L}_1(x), \tag{2.13}$$

其中 $\mathcal{L}_1,\ldots,\mathcal{L}_P$ 是 P 个隐含层, 每个隐藏层的定义如下

$$x_{k+1}=\mathcal{L}_k(x_k)=\phi(W_k\cdot x_k+b_k), \tag{2.14}$$

其中权重 $W_k\in\mathbb{R}^{n_{k+1}\times n_k}$、偏置 $b_k\in\mathbb{R}^{n_{k+1}}$ 为可训练的待定系数, ϕ 为非线性的激活函数. $\mathcal{L}_O$ 为输出层, 一般为一个线性映射. 深度神经网络的光滑性由激活函数的光滑性保证, 例如 ReLu [71] 是非光滑的, 一般不用于拟合势函数. 此外, 实践证明加入跳跃连接对于提高精度很有帮助 [72]

$$x_{k+1}=x_k+\phi(W_k\cdot x_k+b_k) \tag{2.15}$$

对深度神经网络的表示能力的研究一直是人们重点关心的问题. Barron 证明 [73,74], 只有一个隐含层 ($P=1$) 且任意宽的神经网络可以以任意精度逼近一类函数. Barron 的工作同时给出了渐进逼近效率. 之后, 很多学者对深度神经网络 ($P>1$) 的逼近能力做了理论研究 [75–78], 并解释为什么深的网络比宽的网络更受青睐. 鄂维南等人的工作解释了深度神经网络为什么适用于处理高维问题 [79,80].

2.2. 描述子构造

2.2.1. Behler-Parrinello

Behler-Parrinello 构造了具有如下形式的描述子, 被称为对称函数 (Symmetry functions) [28].

$$G_i^{(2)} = \sum_{j\in\mathcal{N}_i} e^{-\eta(r_{ij}-r_s)^2} f_c(r_{ij}), \tag{2.16}$$

$$G_i^{(3)} = 2^{1-\zeta} \sum_{j,k\in\mathcal{N}_i} (1+\lambda\cos\theta_{ijk})^{\zeta} \cdot e^{-\eta(r_{ij}^2+r_{ik}^2+r_{jk}^2)} \times f_c(r_{ij}) f_c(r_{ik}) f_c(r_{jk}), \tag{2.17}$$

这个表达式中, i 是原子序号, η, r_s, λ 和 ζ 都是可调参数. 其中 λ 取值为 ± 1. $f_c(r_{ij})$ 是一个切换函数, 在截断半径处由有限值光滑过渡到 0. 对称函数 $G^{(2)}$ 也被称为径向函数, 其计算开销正比于邻居数. 对称函数 $G^{(3)}$ 也被称为角度函数, 其计算开销正比于邻居数的平方. 可以证明, 对称函数满足对称性要求. 一般对每种原子, 需要构造 50-100 个对称函数以描述周围原子环境 [81], 这需要使用者对这些对称函数调整参数, 以求达到最优训练效果. 对于多组元体系, 调参过程会非常费时费力 [82]. Behler-Parrinello 在很多软件中有实现, 例如 [83–85].

2.2.2. Bispectrum

Bartok 等人于 2010 年提出了如下的描述子构造 [30]. 首先从局域原子密度出发

$$\rho_i(\boldsymbol{r}) = \sum_{j\in\{i\}\bigcup\mathcal{N}_i} \delta(\boldsymbol{r}-\boldsymbol{r}_{ij}) f_c(r_{ij}), \tag{2.18}$$

其中切换函数 $f_c(r_{ij})$ 在截断半径之外为 0, 在截断半径之内定义为 $f_c(r_{ij}) = 1/2 + 1/2\cos(\pi |r_{ij}|/r_c)$. 注意到这是一个定义在三维空间中以原点为球心, 以截断半径为半径的球上的函数, 任意 $\boldsymbol{r}$ 用极坐标可方便表示, 记为 (r,θ,ϕ). 下面引入了如下的坐标变换, 将三维空间中的球变换为四位空间中的三维超球面:

$$(\phi,\theta,\theta_0) = (\tan^{-1}(y/x), \cos^{-1}(z/r), r/r_0), \tag{2.19}$$

其中参数满足 $r_0 > r_c/\pi$. 这样三维空间中定义的密度函数就转化为四维空间中三维球面 S^3 上定义的密度函数. 注意到四维球谐函数在 S^3 上完备, 密度函数可以通过这组球谐函数展开, 这就得到了

$$\rho(\phi,\theta,\theta_0) = \sum_{j=0}^{\infty} \sum_{-j\le m,m'\le j} c_{m',m}^{j} U_{m',m}^{j}(\phi,\theta,\theta_0), \tag{2.20}$$

其中 $U_{m',m}^{j}$, $c_{m',m}^{j}$ 分别为球谐函数及展开系数. Bartok 等人使用如下变换获得 Bispectrum 矩阵

$$B_{j_1,j_2,j} = \sum_{-j_1\le m_1,m_1'\le j_1} \sum_{-j_2\le m_2,m_2'\le j_2} \sum_{-j\le m,m'\le j} (c_{m,m'}^{j})^* \cdot C_{m,m_1,m_2}^{j,j_1,j_2} \cdot C_{m',m_1',m_2'}^{j,j_1,j_2} \cdot c_{m_1,m_1'}^{j_1} \cdot c_{m_2,m_2'}^{j_2}, \tag{2.21}$$

$C_{m,m_1,m_2}^{j,j_1,j_2}$ 为 Clebsch-Gordan 系数. 可以证明 $B_{j_1,j_2,j}$ 满足对称性要求. 显然 Bispectrum 描述子的计算量较大.

2.2.3. 原子位置光滑交叠

Bartok 等人 2013 年的工作并没有试图建立某个局域构型的描述, 而是建立两个局部构型之间距离的保对称性度量, 这种度量被称为原子位置光滑交叠 (Smooth Overlap of Atomic Positions, SOAP) [86]. 他们工作的出发点仍然是局域原子密度

$$\rho_i(\boldsymbol{r}) = \sum_{j\in\mathcal{N}_i} e^{-\frac{1}{2}(\boldsymbol{r}-\boldsymbol{r}_{ij})^2/\sigma^2} f_c(r_{ij}), \tag{2.22}$$

这个局域密度的定义和 (2.18) 略有区别：邻居原子的密度贡献由 δ 函数磨光为高斯分布. 两个局部构型之间的 “距离” 定义为两个局域密度之间的交叠程度, 例如

$$d_{ij} = \int d\boldsymbol{r}\rho_i(\boldsymbol{r})\rho_j(\boldsymbol{r}),$$

当然我们要考虑旋转对称性的影响: 两个看似不一样的局部构型可能通过旋转操作重合. 基于上述考虑, 对构型之间的 “距离” 做如下定义:

$$\tilde{d}_{ij} = \int_{\hat{R}\in SO_3} \Big(\int d\boldsymbol{r}\rho_i(\boldsymbol{r})\rho_j(\hat{R}\boldsymbol{r})\Big)^{\kappa}, \tag{2.23}$$

并做如下的归一化:

$$d_{ij} = \delta^2|\tilde{d}_{ij}|^{\zeta}/|\tilde{d}_{ii}^{\frac{1}{2}}\tilde{d}_{jj}^{\frac{1}{2}}|^{\zeta}. \tag{2.24}$$

下面的问题是如何计算 (2.23) 中的积分获得局域构型之间的距离. 当参数 κ 取 1, (2.23) 退化, 原因是对对称操作 $\hat{R}$ 的积分和对坐标 $\boldsymbol{r}$ 的积分可以互换, 我们从而失去了构型 j 中原子的相对位置信息. 文献 [86] 考虑了 $\kappa = 2$ 和 3 的情形, 我们以 $\kappa = 2$ 为例展示结果. 首先, 假设在一组正交的径向基底下, 局域密度函数有如下球谐展开:

$$\rho_i(r) = \sum_{nlm} c_{nlm}^i g_n(r) Y_{lm}(\hat{\boldsymbol{r}}), \tag{2.25}$$

其中 c_{nlm}^i 为展开系数, $g_n(r)$ 为径向基底, Y_{lm} 为球谐函数. 则可以证明,

$$\tilde{d}_{ij} = \sum_{n,n',l} \tilde{p}_{nn'l}^i \tilde{p}_{nn'l}^j, \quad \tilde{p}_{nn'l}^i = \sum_m (c_{nlm}^i)^* c_{n'lm}^i \tag{2.26}$$

由于 SOAP 给出的不是对某个构型的绝对描述, 而是构型之间的距离, 因此并不适用于深度神经网络, 而非常适用于核方法: 令核矩阵 $K_{ij} = d_{ij}$, 即可得到机器学习势函数模型.

2.2.4. 库伦矩阵

库伦矩阵描述并非针对局域原子环境, 而是针对体系中所有的原子, 一般这样的体系为分子体系, 对周期性体系的推广并不直接. 下面我们假设一个开放边界条件的体系中有一个分子, 其中的原子坐标仍然记为 $\{\boldsymbol{r}_i\}$, 相应的原子电荷记为 $\{Z_i\}$. 则库伦矩阵定义为

$$M_{ij} = \begin{cases} 0.5Z_i^{2.4} & i = j \\ \dfrac{Z_iZ_j}{|\boldsymbol{r}_{ij}|} & i \neq j, \end{cases}$$

库伦矩阵的非对角线项为两个原子之间的库伦相互作用. 库伦矩阵是不具备交换对称性的. 为了满足交换对称性, 求解库伦矩阵的特征值问题, 并对特征值进行排序, 记为 $\{\epsilon_i\}$. 库伦矩阵描述以排序后的特征值序列 $\{\epsilon_i\}^{\text{sort}}$ 为描述子. 库伦矩阵保持了平移和旋转不变性, 但是由于对特征值进行了排序, 本构造连续但不可微.

2.2.5. SchNet 和卷积型描述子

Schutt 等人提出了名为 SchNet 的构造形式 [87,88]. 其中, 每个原子 i 的局域环境被一个特征向量描述, 我们记为 $\boldsymbol{x}_i \in \mathbb{R}^F$, 其中自然数 F 为特征的维数. 原子特征由原子类型和邻居原子坐标决定. SchNet 的原子特征由卷积形式迭代地给出, 由于构造较为复杂, 我们先看最简单的卷积情形, 再推广到 SchNet 的构造. 我们考虑第 $l+1$ 层的特征由第 l 层的特征经过卷积运算给出:

$$\boldsymbol{x}_i^{l+1} = \boldsymbol{x}_i^l + \frac{1}{N_i} \sum_{j \in \mathcal{N}_i} \boldsymbol{x}_j^l * W^l(\boldsymbol{r}_{ij}), \tag{2.27}$$

其中向量 $W^l : \mathbb{R}^3 \to \mathbb{R}^F$ 由过滤器生成网络给出, "$*$" 表示两个向量间的元素元素相乘. 这里, 为得到过滤器生成网络, 我们首先引入嵌入

$$e_k(\boldsymbol{r}_{ij}) = \exp(-\gamma(r_{ij} - \mu_k)), \tag{2.28}$$

在论文 [88] 中作者定义 μ_k 为 $[0, 30]$ Å 上的均匀网格, 以 0.1 Å 为步长. 论文 [87] 中推荐的 γ 取值为 0.1 Å^{-1}. 这样嵌入向量 $\boldsymbol{e}$ 的维数为 300. SchNet 对过滤器生成网络的构造如下

$$W^l(\boldsymbol{r}_{ij}) = \mathrm{ssp} \circ L_F^{(l,2)} \circ \mathrm{ssp} \circ L_F^{(l,1)}(\boldsymbol{e}(\boldsymbol{r}_{ij})), \tag{2.29}$$

其中 L_F 为输出维数为 F 的线性变换层, 非线性变换 ssp 为 shifted softplus 层, 定义为 $\mathrm{ssp}(x) = \ln(0.5e^x + 0.5)$.

公式 (2.27) 给出了简化后的构造, 下面我们给出 SchNet 卷积构造, 每一层卷积定义为:

$$\boldsymbol{x}_i^{l+1} = \boldsymbol{x}_i^l + L_F^{(l,3)} \circ \mathrm{ssp} \circ L_F^{(l,2)} \Big(\frac{1}{N_i} \sum_{j \in \mathcal{N}_i} L_F^{(l,1)}(\boldsymbol{x}_j^l) * W^l(\boldsymbol{r}_{ij}) \Big), \tag{2.30}$$

注意公式 (2.30) 中的 $L_F^{(l,\alpha)}$ 和 (2.29) 中的 $L_F^{(l,\alpha)}$ 不共享参数, 应加以区分. 卷积 (2.30) 中, 在卷积步骤并没有进行跨特征卷积. 卷积后通过线性层对不同特征进行了混合. 在文献 [29] 中作者使用了三个卷积层. 注意每经过一次卷积, 描述子的原子坐标依赖范围就会增大一个截断半径 r_c. 可以证明 SchNet 描述子保持了对称性要求.

更一般地, 我们可以将卷积形式写为

$$\boldsymbol{x}_i^{l+1} = \mathcal{G}^l(\boldsymbol{x}_i^l, \boldsymbol{v}_i^l), \quad \boldsymbol{v}_i^l = \frac{1}{N_i} \sum_{j \in \mathcal{N}_i} \mathcal{F}^l(\boldsymbol{x}_j^l) * \mathcal{W}^l(\boldsymbol{r}_{ij}) \tag{2.31}$$

其中 $\mathcal{F}^l$, $\mathcal{G}^l$, $\mathcal{W}^l$ 为可学习的映射. 特别地, Hierarchically Interacting Particle Neural Network (HIP-NN) 方法 [40] 和 PhysNet 方法 [41] 都可以写为 (2.31) 的形式. 区别在于 $\mathcal{F}^l$, $\mathcal{G}^l$, $\mathcal{W}^l$ 的构造不同. 这些构造均能够保证平移、旋转和交换不变性, 且一般都能做到足够光滑.

2.2.6. 矩张量

矩张量 (Moment tensor) 描述子定义为如下表达式 [32]:

$$M_{\mu,\nu} = \sum_{j \in \mathcal{N}_i} f_\mu(r_{ij}, Z_i, Z_j) \underbrace{\boldsymbol{r}_{ij} \otimes \cdots \otimes \boldsymbol{r}_{ij}}_{\nu \text{ times}}, \tag{2.32}$$

其中 $\otimes$ 表示张量积, 则 $\boldsymbol{r}_{ij} \otimes \cdots \otimes \boldsymbol{r}_{ij}$ 为一个 ν 阶张量. 公式 (2.32) 中的 f_μ 为原子间径向距离的映射, 我们稍后讨论. 为了更直观地理解矩张量, 假设 f_μ 取邻居原子质量 m_j, 则描述子 $M_{\mu,0} = \sum_j m_j$, $M_{\mu,1} = \sum_j m_j \boldsymbol{r}_{ij}$, $M_{\mu,2} = \sum_j m_j \boldsymbol{r}_{ij} \otimes \boldsymbol{r}_{ij}$, 分别为质量的 0 阶, 1 阶, 2 阶

矩. 物理上对应局域原子环境的总质量, 质心和转动惯量矩阵. 对于径向函数 f_μ, 矩张量方法采用了 Chebyshev 多项式展开形式:

$$f_\mu(r_{ij}, Z_i, Z_j) = \sum_k c^k_{\mu,Z_i,Z_j} T_k(r_{ij})(r_c - r_{ij})^2, \tag{2.33}$$

其中 $T_k(r)$ 为区间 $[r_{\min}, r_c]$ 上的 Chebyshev 多项式, $(r_c - r_{ij})^2$ 起到了在截断半径处光滑化描述子的作用. 展开系数 c^k_{μ,Z_i,Z_j} 为可训练参数.

目前 $M_{\mu,\nu}$ 能保证平移和交换对称性, 但是仍不能保证旋转对称性. 为了解决这个问题, 矩张量方法引入了缩并形式解决这个问题, 例如

$$B_{2\mu} = M_{\mu,0}, \tag{2.34}$$

$$B_{2\mu+1} = M_{\mu,1} \cdot M_{\mu,1}, \tag{2.35}$$

$$B_{2\mu+2} = M_{\mu,0}\big(M_{\mu,2} : M_{\mu,2}\big), \tag{2.36}$$

则这里定义的 B_α 满足对称性要求, 可以作为描述子使用. 文献 [32] 证明, 任意旋转且交换不变多项式都可由 B_α 的线性组合表示. 这说明在渐进意义下任何光滑的且具有旋转和交换不变性的函数均可由矩张量近似.

2.2.7. 深度势能 —— 非光滑版本

深度势能描述子有两个版本, 分别为原子坐标的非光滑和光滑映射. 我们从非光滑描述子开始介绍. 非光滑描述子的核心思想是以原子为中心以特定的规则建立局域标架, 将实验室坐标系中的邻居坐标线性变化为此局域标架下的坐标, 从而解决旋转对称性问题. 再将邻居原子按照和中心原子距离远近进行排序解决交换对称性问题. 下面介绍局域标架的构造思想. 首先在 i 的邻居原子 $\mathcal{N}_i$ 中选择两个原子 $a(i) \in \mathcal{N}_i$, $b(i) \in \mathcal{N}_i$. 我们假设 i, $a(i)$, $b(i)$ 这三个原子非共线, 对于一般分子体系总是能找到两个邻居原子满足非共线条件. 我们定义旋转矩阵, 其中每列元素为局域标架中的基矢

$$\mathcal{R}(\boldsymbol{r}_{ia(i)}, \boldsymbol{r}_{ib(i)}) = \begin{pmatrix} \boldsymbol{e}(\boldsymbol{r}_{ia(i)}) \\ \boldsymbol{e}\Big[\boldsymbol{r}_{ib(i)} - \dfrac{\boldsymbol{r}_{ia(i)} \cdot \boldsymbol{r}_{ib(i)}}{\boldsymbol{r}_{ia(i)} \cdot \boldsymbol{r}_{ia(i)}} \boldsymbol{r}_{ia(i)}\Big] \\ \boldsymbol{e}(\boldsymbol{r}_{ia(i)} \times \boldsymbol{r}_{ib(i)}) \end{pmatrix}^T, \tag{2.37}$$

其中记号 $\boldsymbol{e}(\boldsymbol{r}) = \boldsymbol{r}/|\boldsymbol{r}|$, 表示对向量 $\boldsymbol{r}$ 做单位化. 则任意实验室标架中的坐标中的邻居相对坐标 $\boldsymbol{r}_{ij} = (x_{ij}, y_{ij}, z_{ij})$ 可以通过旋转矩阵转化为局域标架 $\boldsymbol{r}'_{ij} = (x'_{ij}, y'_{ij}, z'_{ij})$

$$(x'_{ij}, y'_{ij}, z'_{ij}) = (x_{ij}, y_{ij}, z_{ij}) \cdot \mathcal{R}(\boldsymbol{r}_{ia(i)}, \boldsymbol{r}_{ib(i)}), \tag{2.38}$$

局域标架中的坐标已经和体系的旋转操作无关, 构造描述子时可以直接使用. 但是研究发现使用约化库伦势的坐标对于深度学习更有效率 [37]. 实际中采用如下的描述子构造:

$$\left\{\frac{1}{r_{ij}}, \frac{x'_{ij}}{r_{ij}}, \frac{y'_{ij}}{r_{ij}}, \frac{z'_{ij}}{r_{ij}}\right\}^{\text{sort}}_{j \in \mathcal{N}_i}, \tag{2.39}$$

上表 “sort” 表示邻居坐标出现的顺序为按 r_{ij} 升序排列. 如果邻居原子距离较远, 则可以舍弃角度信息项而只考虑径向信息:

$$\left\{\frac{1}{r_{ij}}\right\}^{\text{sort}}_{j \in \mathcal{N}_i}. \tag{2.40}$$

本描述子的优点是全部邻居信息得以保留, 描述局域环境的能力强. 缺点是描述子不光滑, 不光滑性来源于决定标架的邻居原子 $a(i)$ 和 $b(i)$ 选择的不确定性. 在实际操作中, 一般取 $a(i)$ 为最近邻原子, $b(i)$ 为次近邻原子, 但是由于原子坐标的连续变化会导致近邻原子序号的非连续变化, 从而引起局域标架非连续变化, 进而导致局域坐标非连续变化. 另外, 对于其他原子的排序操作也会在描述子 (2.39) 中引入非连续性, 在描述子 (2.40) 中引入一阶导数非连续性.

2.2.8. 深度势能 —— 光滑版本

为构造光滑版本深度势能描述子, 我们首先对原子 i 的环境矩阵的定义稍作修改

$$\big(\mathcal{R}_i\big)_{j,\cdot} = s(r_{ij}) \times \Big(\frac{x_{ij}}{r_{ij}}, \frac{y_{ij}}{r_{ij}}, \frac{z_{ij}}{r_{ij}}\Big), \tag{2.41}$$

其中 $s(r_{ij}) = f_c(r_{ij})/r_{ij}$. 实际操作中, 会以补 0 的方式将增广环境矩阵的行数扩充至最大邻居数. 同时构造增广环境矩阵 $\tilde{\mathcal{R}}_i \in \mathbb{R}^{N_i\times 4}$, 这个矩阵相比环境矩阵增加一列. 增广环境矩阵 $\tilde{\mathcal{R}}_i$ 的每一行元素定义为

$$\big(\tilde{\mathcal{R}}_i\big)_{j,\cdot} = s(r_{ij}) \times \Big(1, \frac{x_{ij}}{r_{ij}}, \frac{y_{ij}}{r_{ij}}, \frac{z_{ij}}{r_{ij}}\Big), \tag{2.42}$$

将增广环境矩阵的第一列, 也就是只蕴含了邻居原子距离的列取出, 构造径向嵌入矩阵 $\mathcal{G}_i \in \mathbb{R}^{N_i\times M}$, 嵌入矩阵列数为邻居数, 每一行的定义为

$$\big(\mathcal{G}_i^{(2)}\big)_{j,\cdot} = \Big(G_1^{(2)}(s(r_{ij}), Z_j), \ldots, G_M^{(2)}(s(r_{ij}), Z_j)\Big), \tag{2.43}$$

其中标量型输入 $s(r_{ij})$ 被映射到向量 $(G_1^{(2)}, \ldots, G_M^{(2)})$, 这个映射是由可训练的深度神经网络表示的. 对于输入类型 Z_j 既可以分情况讨论 (原子类型数有限), 又可以将类型输入嵌入网络. 注意嵌入的输入只接收邻居原子 j 的类型, 同时接收 i, j 的类型也是可以的, 不过对提高模型精度几乎没有帮助. 这里 Z 一般理解为类型空间中的某个表示, 而不理解为原子序数. 另外, 可以构造角度相关的嵌入项

$$\big(\mathcal{G}_i^{(3)}\big)_{j,k,\cdot} = \Big(G_1^{(3)}((\theta_i)_{jk}, Z_j, Z_k), \ldots, G_M^{(3)}((\theta_i)_{jk}, Z_j, Z_k)\Big), \tag{2.44}$$

其中以 i 为中心, 邻居 j 和 k 形成的夹角的信息被表示为环境矩阵 j 和 k 行的内积

$$(\theta_i)_{jk} = (\mathcal{R}_i)_{j,\cdot} \cdot (\mathcal{R}_i)_{k,\cdot} \tag{2.45}$$

嵌入网络的输入维数一般很低, 而输出维数一般为数十. 此时一般使用后一层相比前一层逐层扩大的网络构造, 比如使用隐含层为 20, 40, 80 个神经元的构造. 当后一层神经元数为前一层的 2 倍时, 可以构造如下的跳转链接方式:

$$\boldsymbol{y} = (\boldsymbol{x}, \boldsymbol{x}) + \Delta * \phi(\boldsymbol{W}\boldsymbol{x} + \boldsymbol{b}), \tag{2.46}$$

其中 $(\boldsymbol{x}, \boldsymbol{x})$ 表示对两个列向量沿列方向连接. Δ 是可训练参数, 长度和 y 相同. $*$ 表示 Δ 和 ϕ 每个元素相乘.

根据嵌入 (2.43), (2.44), 我们可以分别从径向嵌入和角度嵌入构造描述子

$$\mathcal{D}^{(2,r)} = \frac{1}{N_i}\sum_j \big(\mathcal{G}_i^{(2)}\big)_{j,\cdot} \tag{2.47}$$

$$\mathcal{D}^{(2,a)} = \frac{1}{N^2(i)}(\mathcal{G}_i^{(2),<})^T \tilde{\mathcal{R}}_i (\tilde{\mathcal{R}}_i)^T \mathcal{G}_i^{(2)} \tag{2.48}$$

$$\mathcal{D}^{(3)} = \frac{1}{N^2(i)}\big(\tilde{\mathcal{R}}_i(\tilde{\mathcal{R}}_i)^T\big) : \mathcal{G}_i^{(3)}, \tag{2.49}$$

其中选取 $\mathcal{G}_i^{(2)}$ 的前 $M_<$ 列形成子矩阵 $\mathcal{G}_i^{(2),<}$. 其中两体嵌入 $\mathcal{D}^{(2,r)}$ 只依赖于邻居原子的径向距离. 两体嵌入 $\mathcal{D}^{(2,a)}$ 依赖于邻居原子的空间坐标, 但嵌入项只依赖于距离. 三体嵌入在嵌入项中就考虑了邻居原子的相对位置的夹角. 因此, 从描述能力评价, $\mathcal{G}_i^{(3)}$ 高于 $\mathcal{D}^{(2,a)}$ 高于 $\mathcal{D}^{(2,r)}$. 同时, 描述能力强的描述子训练难度也更大. 因此一般将这些描述子中的两个或全部结合使用. 例如使用 $\mathcal{G}_i^{(3)}$ 描述一个较小的截断半径内的邻居构型, $\mathcal{G}_i^{(2,a)}$ 描述一个较大的截断半径内的邻居构型. 而 $\mathcal{G}_i^{(2,r)}$ 描述更远的邻居原子构型. 不难证明这些描述子构造均满足对称性要求.

2.2.9. 描述子的完备性

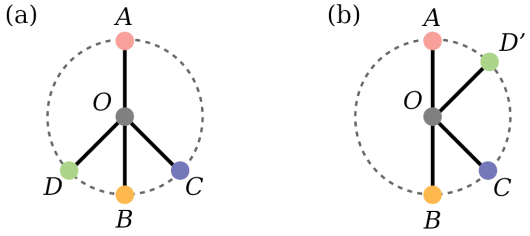

图 1 反例 (来源于文献 [43]): 子图 (a) 和 (b) 是不同的构型, 但是其邻居距离和夹角的出现频率相同. 图 (a), (b) 中所有邻居原子到中心原子 O 的距离相同. 图 (a) 中角度 BOD, BOC 为 $\pi/4$, 图 (b) 中角度 BOC, AOD' 为 $\pi/4$. 两子图中角度 AOB 为 π. 以原子 O 为中心的所有原子间夹角的出现频率是相同的: $\pi/4$ 两次, $\pi/2$ 一次, $3\pi/4$ 两次, π 一次

虽然基于描述子的机器学习势函数建模在实际中取得了巨大的成功, 但是描述子的完备性仍有待研究. 一组完备的描述子的意义是 (1) 对于任意两个局域结构, 如果他们无法通过平移、旋转、交换操作重合, 则描述子不同. (2) 对于任意两个局域结构, 如果他们能够通过平移、旋转、交换操作重合, 则描述子相同. 最简单地, 本文中提到的绝大多数描述子基于对相邻原子间距离, 任两个相邻原子间夹角的频率的描述. 然而基于频率的描述子并不完备, 可以举出反例使基于频率的描述子不满足条件 (1) [89]. 例如图 1 中, 两个子图中的构型中所有邻居原子 $\{A, B, C, D, D'\}$ 到中心原子 O 的距离相同, 考察任意两个邻居原子和中心原子 O 的夹角, 这些夹角的出现频率相同, 为 $\pi/4$ 两次, $\pi/2$ 一次, $3\pi/4$ 两次, π 一次. 但是, 子图 (b) 中的原子构型, 无法通过平移、旋转、交换等变换得到与 (a) 相同的构型. 因此基于原子间距离和夹角频率的描述子都是不完备的. 本文介绍的描述子中 Behler-Parrinello, SOAP, 卷积型描述子, 深度势能的光滑版本都不完备. 深度势能的非光滑版本是完备的, 但是不具有光滑性. Bispectrum 描述子基于邻居原子距离, 角度和四体构型的频率 [89], 因此虽然能够分辨角度频率相同的构型. 但是仍然能举出反例, 不等价的构型具有相同的距离、夹角和四体构型的频率, 此时 Bispectrum 描述子无法分辨. 矩张量描述子能够通过系统性地增加展开阶数逼近完备, 但是此时计算开销将显著增加. 如何设计完备、光滑且计算量较小的描述子仍然是一个开放的问题.

3. 结论和展望

本文回顾了基于机器学习的原子间相互作用建模方法. 我们从构造原子间相互作用模型的基本要求出发, 给出了原子间相互作用的较为通用的表达, 并在这个表达式下回顾了文献

中报道的建模方法. 值得注意的是, 由于基于机器学习的原子间相互作用建模工作极多, 本文的回顾难免有所遗漏. 目前对于这些机器学习的原子间相互作用建模方法, 从精度和效率方面, 缺乏系统性比较, 因此对这些方法的相对性能并没有较为公认的认识. 其中最主要的原因之一是缺乏公认的, 且难度较高的数据集. 现有广泛应用的数据集, 例如 QM-9 [90,91], 难度相对较低, 无法充分反映不同方法的能力差别. 领域中迫切需要建设类似于 ImageNet [92] 的对领域推动作用极大的数据集. 本文主要回顾机器学习势模型的建模工作, 也就是体系能量如何表示为原子坐标的函数的问题. 产生一个具有一定适用范围的机器学习势还需要解决数据生成问题, 例如很多机器学习力场使用主动学习/同步学习算法生成数据 [43–52]. 此外, 机器学习对其他物理量的建模工作在文献中有大量报道, 比如偶极 [41,93–96], 极化率 [97–99], 电荷密度 [93,100–106] 等物理量. 以及使用机器学习方法构造粗粒化势函数 [107–109]. 这些工作和本文的主题高度相关, 但由于篇幅限制暂不展开论述.

参 考 文 献

[1] Abrams C, Bussi G. Enhanced sampling in molecular dynamics using metadynamics, replica-exchange, and temperature-acceleration[J]. Entropy, 2014, 16(1): 163–199.

[2] Bernardi R C, Melo M C, Schulten K. Enhanced sampling techniques in molecular dynamics simulations of biological systems[J]. Biochimica et Biophysica Acta (BBA)-General Subjects, 2015, 1850(5): 872–877.

[3] Yang Y I, Shao Q, Zhang J, Yang L, Gao Y Q. Enhanced sampling in molecular dynamics[J]. The Journal of chemical physics, 2019, 151(7): 070902.

[4] Born M, Oppenheimer R. Zur quantentheorie der molekeln[J]. Annalen der physik, 1927, 389(20): 457–484.

[5] Schrödinger E. An undulatory theory of the mechanics of atoms and molecules[J]. Physical review, 1926, 28(6): 1049.

[6] Hohenberg P, Kohn W. Inhomogeneous electron gas[J]. Physical review, 1964, 136(3B): B864.

[7] Kohn W, Sham L J. Self-consistent equations including exchange and correlation effects[J]. Physical review, 1965, 140(4A): A1133.

[8] Møller C, Plesset M. Note on an approximation treatment for many-electron systems[J]. Physical review, 1934, 46(7): 618.

[9] Čížek J. On the correlation problem in atomic and molecular systems. Calculation of wave-function components in Ursell-type expansion using quantum-field theoretical methods[J]. The Journal of Chemical Physics, 1966, 45(11): 4256–4266.

[10] Car R, Parrinello M. Unified approach for molecular dynamics and density-functional theory[J]. Physical review letters, 1985, 55(22): 2471.

[11] Daura X, Mark A E, Gunsteren W F V. Parametrization of aliphatic CHn united atoms of GROMOS96 force field[J]. Journal of Computational Chemistry, 1998, 19(5): 535–547.

[12] Schuler L D, Daura X, Gunsteren W F V. An improved GROMOS96 force field for aliphatic hydrocarbons in the condensed phase[J]. Journal of Computational Chemistry, 2001, 22(11): 1205–1218.

[13] MacKerell A, Bashford D, Bellott M, Dunbrack R, Evanseck J, Field M, Fischer S, Gao J, Guo H, Ha S, Joseph-McCarthy S, Kuchnir L, Kuczera K, Lau F, Mattos C, Michnick S, Ngo T, Nguyen D, Prodhom B, III W R, Roux B, Schlenkrich M, Smith J, Stote R, Straub J,

Watanabe M, Wiórkiewicz-Kuczera J, Yin D, Karplus M. All-atom empirical potential for molecular modeling and dynamics studies of proteins[J]. The Journal of Physical Chemistry B, 1998, 102(18): 3586–3616.

[14] Vanommeslaeghe K, Hatcher E, Acharya C, S. Kundu S Z, Shim J, Darian E, Guvench O, Lopes P, Vorobyov I, Jr. A M. CHARMM general force field: A force field for drug-like molecules compatible with the CHARMM all-atom additive biological force fields[J]. Journal of computational chemistry, 2010, 31(4): 671–690.

[15] MacKerell A D, Feig M, III C L B. Extending the treatment of backbone energetics in protein force fields: Limitations of gas-phase quantum mechanics in reproducing protein conformational distributions in molecular dynamics simulations [J]. Journal of computational chemistry, 2004, 25(11): 1400–1415.

[16] Yu Y, Krämer A, Venable R M, Brooks B R, Klauda J B, Pastor R W. CHARMM36 Lipid Force Field with Explicit Treatment of Long-Range Dispersion: Parametrization and Validation for Phosphatidylethanolamine, Phosphatidylglycerol, and Ether Lipids[J]. Journal of Chemical Theory and Computation, 2021.

[17] Wang J, Wolf R M, Caldwell J W, Kollman P A, Case D A. Development and testing of a general amber force field [J]. Journal of computational chemistry, 2004, 25(9): 1157–1174.

[18] Hornak V, Abel R, Okur A, Strockbine B, Roitberg A, Simmerling C. Comparison of multiple Amber force fields and development of improved protein backbone parameters[J]. Proteins: Structure, Function, and Bioinformatics, 2006, 65(3): 712–725.

[19] Lindorff-Larsen K, Piana S, Palmo K, Maragakis P, Klepeis J L, Dror R O, Shaw D E. Improved side-chain torsion potentials for the Amber ff99SB protein force field[J]. Proteins: Structure, Function, and Bioinformatics, 2010, 78(8): 1950–1958.

[20] Jorgensen W, Maxwell D, Tirado-Rives J. Development and testing of the OPLS all-atom force field on conformational energetics and properties of organic liquids[J]. Journal of the American Chemical Society, 1996, 118(45): 11225–11236.

[21] Duin A C V, Dasgupta S, Lorant F, Goddard W A. ReaxFF: a reactive force field for hydrocarbons[J]. The Journal of Physical Chemistry A, 2001, 105(41): 9396–9409.

[22] Chenoweth K, Duin A C V, Goddard W A. ReaxFF reactive force field for molecular dynamics simulations of hydrocarbon oxidation[J]. The Journal of Physical Chemistry A, 2008, 112(5): 1040–1053.

[23] Senftle T P, Hong S, Islam M M, Kylasa S B, Zheng Y, Shin Y K, Junkermeier C, Engel-Herbert R, Janik M J, Aktulga H M, et al. The ReaxFF reactive force-field: development, applications and future directions[J]. npj Computational Materials, 2016, 2(1): 1–14.

[24] Daw M S, Baskes M I. Embedded-atom method: Derivation and application to impurities, surfaces, and other defects in metals[J]. Physical Review B, 1984, 29(12): 6443.

[25] Daw M S, Foiles S M, Baskes M I. The embedded-atom method: a review of theory and applications[J]. Materials Science Reports, 1993, 9(7-8): 251–310.

[26] Lee B J, Baskes M. Second nearest-neighbor modified embedded-atom-method potential[J]. Physical Review B, 2000, 62(13): 8564.

[27] Tchipev N, Seckler S, Heinen M, Vrabec J, Gratl F, Horsch M, Bernreuther M, Glass C W, Niethammer C, Hammer N, et al. TweTriS: Twenty trillion-atom simulation[J]. The International Journal of High Performance Computing Applications, 2019, 33(5): 838–854.

[28] Behler J, Parrinello M. Generalized neural-network representation of high-dimensional potential-

energy surfaces[J]. Physical review letters, 2007, 98(14): 146401.

[29] Schütt K T, Arbabzadah F, Chmiela S, Müller K R, Tkatchenko A. Quantum-chemical insights from deep tensor neural networks[J]. Nature communications, 2017, 8: 13890.

[30] Bartók A P, Payne M C, Kondor R, Csányi G. Gaussian approximation potentials: The accuracy of quantum mechanics, without the electrons[J]. Physical review letters, 2010, 104(13): 136403.

[31] Rupp M, Tkatchenko A, Müller K R, Lilienfeld O A V. Fast and accurate modeling of molecular atomization energies with machine learning[J]. Physical review letters, 2012, 108(5): 058301.

[32] Shapeev A V. Moment tensor potentials: A class of systematically improvable interatomic potentials[J]. Multiscale Modeling & Simulation, 2016, 14(3): 1153–1173.

[33] Smith J S, Isayev O, Roitberg A E. ANI-1: an extensible neural network potential with DFT accuracy at force field computational cost[J]. Chemical Science, 2017, 8(4): 3192–3203.

[34] Chmiela S, Tkatchenko A, Sauceda H E, Poltavsky I, Schütt K T, Müller K R. Machine learning of accurate energy-conserving molecular force fields[J]. Science Advances, 2017, 3(5): e1603015.

[35] Chmiela S, Sauceda H E, Müller K R, Tkatchenko A. Towards exact molecular dynamics simulations with machine-learned force fields[J]. Nature communications, 2018, 9(1): 1–10.

[36] Yao K, Herr J E, Toth D W, Mckintyre R, Parkhill J. The TensorMol-0.1 model chemistry: a neural network augmented with long-range physics[J]. Chemical science, 2018, 9(8): 2261–2269.

[37] Han J, Zhang L, Car R, et al. Deep Potential: A General Representation of a Many-Body Potential Energy Surface[J]. Communications in Computational Physics, 2018, 23(3).

[38] Zhang L, Han J, Wang H, Car R, Weinan E. Deep potential molecular dynamics: a scalable model with the accuracy of quantum mechanics[J]. Physical review letters, 2018, 120(14): 143001.

[39] Zhang L, Han J, Wang H, Saidi W A, Car R, Weinan E. End-to-end symmetry preserving inter-atomic potential energy model for finite and extended systems[J]. Advances in Neural Information Processing Systems, 2018, 2018: 4436–4446.

[40] Lubbers N, Smith J S, Barros K. Hierarchical modeling of molecular energies using a deep neural network[J]. The Journal of Chemical Physics, 2018, 148(24): 241715.

[41] Unke O T, Meuwly M. PhysNet: a neural network for predicting energies, forces, dipole moments and partial charges[J]. Journal of chemical theory and computation, 2019.

[42] Bartok A P, Kermode J, Bernstein N, Csanyi G. Machine learning a general purpose interatomic potential for silicon[J]. arXiv preprint arXiv:1805.01568, 2018.

[43] Podryabinkin E V, Shapeev A V. Active learning of linearly parametrized interatomic potentials[J]. Computational Materials Science, 2017, 140: 171–180.

[44] Smith J S, Nebgen B, Lubbers N, Isayev O, Roitberg A E. Less is more: Sampling chemical space with active learning[J]. The Journal of Chemical Physics, 2018, 148(24): 241733.

[45] Uteva E, Graham R S, Wilkinson R D, Wheatley R J. Active learning in Gaussian process interpolation of potential energy surfaces[J]. The Journal of chemical physics, 2018, 149(17): 174114.

[46] Gubaev K, Podryabinkin E V, Shapeev A V. Machine learning of molecular properties: Locality and active learning[J]. The Journal of Chemical Physics, 2018, 148(24): 241727.

[47] Zhang L, Lin D Y, Wang H, Car R, Weinan E. Active learning of uniformly accurate interatomic potentials for materials simulation[J]. Physical Review Materials, 2019, 3(2): 023804.

[48] Schran C, Behler J, Marx D. Automated Fitting of Neural Network Potentials at Coupled Cluster Accuracy: Protonated Water Clusters as Testing Ground[J]. Journal of chemical theory and computation, 2019.

[49] Jinnouchi R, Lahnsteiner J, Karsai F, Kresse G, Bokdam M. Phase Transitions of Hybrid

Perovskites Simulated by Machine-Learning Force Fields Trained on the Fly with Bayesian Inference[J]. Physical Review Letters, 2019, 122(22): 225701.

[50] Zhang Y, Wang H, Chen W, Zeng J, Zhang L, Wang H, Weinan E. DP-GEN: A concurrent learning platform for the generation of reliable deep learning based potential energy models[J]. Computer Physics Communications, 2020, 253: 107206.

[51] Lin Q, Zhang L, Zhang Y, Jiang B. Searching Configurations in Uncertainty Space: Active Learning of High-Dimensional Neural Network Reactive Potentials[J]. Journal of Chemical Theory and Computation, 2021.

[52] Imbalzano G, Zhuang Y, Kapil V, Rossi K, Engel E A, Grasselli F, Ceriotti M. Uncertainty estimation for molecular dynamics and sampling[J]. The Journal of Chemical Physics, 2021, 154(7): 074102.

[53] Gartner T E, Zhang L, Piaggi P M, Car R, Panagiotopoulos A Z, Debenedetti P G. Signatures of a liquid–liquid transition in an ab initio deep neural network model for water[J]. Proceedings of the National Academy of Sciences, 2020, 117(42): 26040–26046.

[54] Zhang L, Wang H, Car R, Weinan E. Phase Diagram of a Deep Potential Water Model[J]. Physical Review Letters, 2021, 126(23): 236001.

[55] Artrith N, Morawietz T, Behler J. High-dimensional neural-network potentials for multicomponent systems: Applications to zinc oxide[J]. Physical Review B, 2011, 83(15): 153101.

[56] Bereau T, Andrienko D, von Lilienfeld O A. Transferable atomic multipole machine learning models for small organic molecules[J]. Journal of Chemical Theory and Computation, 2015.

[57] Bereau T, Jr R A D, Tkatchenko A, Lilienfeld O A V. Non-covalent interactions across organic and biological subsets of chemical space: Physics-based potentials parametrized from machine learning[J]. The Journal of Chemical Physics, 2018, 148(24): 241706.

[58] Nebgen B, Lubbers N, Smith J S, Sifain A, Lokhov A, Isayev O, Roitberg A, Barros K, Tretiak S. Transferable Molecular Charge Assignment Using Deep Neural Networks[J]. arXiv preprint arXiv:1803.04395, 2018.

[59] Sifain A E, Lubbers N, Nebgen B T, Smith J S, Lokhov A Y, Isayev O, Roitberg A E, Barros K, Tretiak S. Discovering a transferable charge assignment model using machine learning[J]. The journal of physical chemistry letters, 2018, 9(16): 4495–4501.

[60] Ghasemi S A, Hofstetter A, Saha S, Goedecker S. Interatomic potentials for ionic systems with density functional accuracy based on charge densities obtained by a neural network [J]. Physical Review B, 2015, 92(4): 045131.

[61] Ko T W, Finkler J A, Goedecker S, Behler J. A fourth-generation high-dimensional neural network potential with accurate electrostatics including non-local charge transfer[J]. Nature communications, 2021, 12(1): 1–11.

[62] Ko T W, Finkler J A, Goedecker S, Behler J. General-Purpose Machine Learning Potentials Capturing Nonlocal Charge Transfer[J]. Accounts of Chemical Research, 2021, 54(4): 808–817.

[63] Grisafi A, Ceriotti M. Incorporating long-range physics in atomic-scale machine learning[J]. The Journal of chemical physics, 2019, 151(20): 204105.

[64] Grisafi A, Nigam J, Ceriotti M. Multi-scale approach for the prediction of atomic scale properties[J]. Chemical Science, 2021, 12(6): 2078–2090.

[65] Mahoney M W, Drineas P. CUR matrix decompositions for improved data analysis [J]. Proceedings of the National Academy of Sciences, 2009, 106(3): 697–702.

[66] Imbalzano G, Anelli A, Giofré D, Klees S, Behler J, Ceriotti M. Automatic selection of atom-

ic fingerprints and reference configurations for machine-learning potentials[J]. The Journal of chemical physics, 2018, 148(24): 241730.

[67] Krizhevsky A, Sutskever I, Hinton G E. Imagenet classification with deep convolutional neural networks[J]. Advances in neural information processing systems, 2012, 25: 1097–1105.

[68] Wolf T, Chaumond J, Debut L, Sanh V, Delangue C, Moi A, Cistac P, Funtowicz M, Davison J, Shleifer S, et al. Transformers: State-of-the-art natural language processing [C]. In Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing: System Demonstrations, 2020, 38–45.

[69] Senior A W, Evans R, Jumper J, Kirkpatrick J, Sifre L, Green T, Qin C, Žídek A, Nelson A W, Bridgland A, et al. Improved protein structure prediction using potentials from deep learning[J]. Nature, 2020, 1–5.

[70] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015, 521(7553): 436–444.

[71] Hahnloser R H, Sarpeshkar R, Mahowald M A, Douglas R J, Seung H S. Digital selection and analogue amplification coexist in a cortex-inspired silicon circuit[J]. Nature, 2000, 405(6789): 947–951.

[72] He K, Zhang X, Ren S, Sun J. Deep residual learning for image recognition [C]. In Proceedings of the IEEE conference on computer vision and pattern recognition, 2016, 770–778.

[73] Barron A R. Universal approximation bounds for superpositions of a sigmoidal function[J]. IEEE Transactions on Information theory, 1993, 39(3): 930–945.

[74] Barron A R. Approximation and estimation bounds for artificial neural networks[J]. Machine learning, 1994, 14(1): 115–133.

[75] Liang S, Srikant R. Why deep neural networks for function approximation? [J]. arXiv preprint arXiv:1610.04161, 2016.

[76] Telgarsky M. benefits of depth in neural networks [C]. In Conference on Learning Theory, 2016, 1517–1539.

[77] Yarotsky D. Error bounds for approximations with deep ReLU networks [J]. Neural Networks, 2017, 94: 103–114.

[78] Lu J, Shen Z, Yang H, Zhang S. Deep network approximation for smooth functions[J]. arXiv preprint arXiv:2001.03040, 2020.

[79] E W, Ma C, Wu L. A priori estimates of the population risk for two-layer neural networks[J]. Communications in Mathematical Sciences, 2019, 17(5): 1407–1425.

[80] E W, Ma C, Wu L. The Barron Space and the Flow-Induced Function Spaces for Neural Network Models[J]. Constructive Approximation, 2021, 1–38.

[81] Behler J. Perspective: Machine learning potentials for atomistic simulations[J]. The Journal of Chemical Physics, 2016, 145(17): 170901.

[82] Hajinazar S, Shao J, Kolmogorov A N. Stratified construction of neural network based interatomic models for multicomponent materials[J]. Physical Review B, 2017, 95(1): 014114.

[83] Singraber A, Behler J, Dellago C. Library-Based LAMMPS Implementation of High-Dimensional Neural Network Potentials[J]. Journal of chemical theory and computation, 2019, 15(3): 1827–1840.

[84] Lee K, Yoo D, Jeong W, Han S. SIMPLE-NN: An efficient package for training and executing neural-network interatomic potentials[J]. Computer Physics Communications, 2019, 242: 95–103.

[85] Himanen L, Jäger M O, Morooka E V, Canova F F, Ranawat Y S, Gao D Z, Rinke P, Foster A S. DScribe: Library of descriptors for machine learning in materials science[J]. Computer Physics

Communications, 2020, 247: 106949.

[86] Bartók A P, Kondor R, Csányi G. On representing chemical environments[J]. Physical Review B, 2013, 87(18): 184115.

[87] Schütt K T, Sauceda H E, Kindermans P J, Tkatchenko A, Müller K R. SchNet–A deep learning architecture for molecules and materials[J]. The Journal of Chemical Physics, 2018, 148(24): 241722.

[88] Schütt K, Kindermans P J, Felix H E S, Chmiela S, Tkatchenko A, Müller K R. SchNet: A continuous-filter convolutional neural network for modeling quantum interactions [C]. In Advances in Neural Information Processing Systems, 2017, 991–1001.

[89] Pozdnyakov S N, Willatt M J, Bartók A P, Ortner C, Csányi G, Ceriotti M. On the Completeness of Atomic Structure Representations [J]. arXiv preprint arXiv:2001.11696, 2020.

[90] Ruddigkeit L, Deursen R V, Blum L C, Reymond J L. Enumeration of 166 billion organic small molecules in the chemical universe database GDB-17[J]. Journal of chemical information and modeling, 2012, 52(11): 2864–2875.

[91] Ramakrishnan R, Dral P O, Rupp M, Lilienfeld O A V. Quantum chemistry structures and properties of 134 kilo molecules[J]. Scientific data, 2014, 1(1): 1–7.

[92] Deng J, Dong W, Socher R, Li L J, Li K, Fei-Fei L. Imagenet: A large-scale hierarchical image database [C]. In 2009 IEEE conference on computer vision and pattern recognition, Ieee, 2009, 248–255.

[93] Grisafi A, Wilkins D M, Csányi G, Ceriotti M. Symmetry-Adapted Machine Learning for Tensorial Properties of Atomistic Systems[J]. Physical Review Letters, 2018, 120(3): 036002.

[94] Pereira F, de Sousa J A. Machine learning for the prediction of molecular dipole moments obtained by density functional theory[J]. Journal of cheminformatics, 2018, 10(1): 43.

[95] Glick Z L, Koutsoukas A, Cheney D L, Sherrill C D. Cartesian message passing neural networks for directional properties: Fast and transferable atomic multipoles[J]. The Journal of Chemical Physics, 2021, 154(22): 224103.

[96] Zhang L, Chen M, Wu X, Wang H, Weinan E, Car R. Deep neural network for the dielectric response of insulators[J]. Physical Review B, 2020, 102(4): 041121.

[97] Wilkins D M, Grisafi A, Yang Y, Lao K U, DiStasio R A, Ceriotti M. Accurate molecular polarizabilities with coupled cluster theory and machine learning[J]. Proceedings of the National Academy of Sciences, 2019, 116(9): 3401–3406.

[98] Raimbault N, Grisafi A, Ceriotti M, Rossi M. Using Gaussian process regression to simulate the vibrational Raman spectra of molecular crystals[J]. New Journal of Physics, 2019, 21(10): 105001.

[99] Sommers G M, Andrade M F C, Zhang L, Wang H, Car R. Raman spectrum and polarizability of liquid water from deep neural networks[J]. Physical Chemistry Chemical Physics, 2020, 22(19): 10592–10602.

[100] Brockherde F, Vogt L, Li L, Tuckerman M E, Burke K, Müller K R. Bypassing the Kohn-Sham equations with machine learning [J]. Nature communications, 2017, 8(1): 872.

[101] Ryczko K, Strubbe D A, Tamblyn I. Deep learning and density-functional theory[J]. Physical Review A, 2019, 100(2): 022512.

[102] Borda E J L, Samanta A. A practical approach to Hohenberg-Kohn maps based on many-body correlations: learning the electronic density[J]. arXiv preprint arXiv:2004.14442, 2020.

[103] Chandrasekaran A, Kamal D, Batra R, Kim C, Chen L, Ramprasad R. Solving the electronic structure problem with machine learning[J]. npj Computational Materials, 2019, 5(1): 22.

[104] Zepeda-Núñez L, Chen Y, Zhang J, Jia W, Zhang L, Lin L. Deep Density: circumventing the Kohn-Sham equations via symmetry preserving neural networks[J]. arXiv preprint arXiv:1912.00775, 2019.

[105] Bogojeski M, Brockherde F, Vogt-Maranto L, Li L, Tuckerman M E, Burke K, Müller K R. Efficient prediction of 3D electron densities using machine learning[J]. arXiv preprint arXiv:1811.06255, 2018.

[106] Fabrizio A, Grisafi A, Meyer B, Ceriotti M, Corminboeuf C. Electron density learning of non-covalent systems[J]. Chemical science, 2019, 10(41): 9424–9432.

[107] Zhang L, Han J, Wang H, Car R, E W. DeePCG: Constructing coarse-grained models via deep neural networks[J]. The Journal of chemical physics, 2018, 149(3): 034101.

[108] Wang W, Gómez-Bombarelli R. Coarse-graining auto-encoders for molecular dynamics [J]. npj Computational Materials, 2019, 5(1): 1–9.

[109] Wang J, Olsson S, Wehmeyer C, Pérez A, Charron N E, Fabritiis G D, Noé F, Clementi C. Machine learning of coarse-grained molecular dynamics force fields[J]. ACS central science, 2019, 5(5): 755–767.

MOLECULAR MODELING BY MACHIN LEARNING

Wang Han

(*Laboratory of Computational Physics, Institute of Applied Physics and Computational Mathematics, Fenghao East Road 2, Beijing 100094, China;*
HEDPS, CAPT, Peking University, Beijing 100871, China)

Abstract

Modeling the interatomic potential is one of the crucial problems in the field of molecular simulation. For a long time, the community faces the dilemma that the first-principles calculations are accurate but slow, while the empirical force fields are efficient but inaccurate. Machine learning is a promising approach to solve the dilemma because it achieves comparable accuracy with the first-principles calculations at a much lower expense. In this review, we present a general framework for developing the machine learning interatomic potentials, provide an incomplete list of recent work in this direction, and investigate the advantages and disadvantages of the reviewed approaches.

Keywords: Machine learning; Interactomic potential; Molecular dynamics.

2010 Mathematics Subject Classification: 68T99, 74A25, 81V55.